

Laporan Praktikum Kontrol Cerdas

Minggu ke - 4

Nama : Ikhsan Fadila
NIM : 224308035
Kelas : TKA-6B
Akun Github : <https://github.com/Fadila-uhuy>
Student Lab Assistant : Mas Alfian

1. Judul Percobaan: *Reinforcement Learning for Autonomous Control with DQN*
2. Tujuan Percobaan:
 - Memahami konsep dasar Reinforcement Learning (RL) dalam sistem kendali.
 - Mengimplemtasikan agen RL menggunakan algoritma *Deep Q-Network* (DQN).
 - Menggunakan OpenAI Gym sebagai simulasi lingkungan untuk pelatihan RL.
 - Melatih dan menguji agen RL untuk mengontrol lingkungan secara otonom.
 - Menggunakan GitHub untuk version control dan dokumentasi praktikum.
3. Landasan Teori:

Reinforcement learning merupakan cabang kecerdasan buatan yang melatih algoritma melalui sistem *trial and error*. Dalam prosesnya, RL berinteraksi dengan lingkungan dan mengamati dampak dari setiap tindakan yang dilakukan, baik dalam bentuk hadiah maupun hukuman. Informasi yang diperoleh dari interaksi ini digunakan oleh RL untuk memperbarui dan meningkatkan pengetahuannya (Andreanus & Kurniawan, 2018). Dibandingkan dengan metode lain dalam Machine Learning, algoritma Reinforcement Learning memiliki keunggulan tersendiri. Salah satu yang paling menonjol adalah kemampuannya untuk secara mandiri mengeksplorasi lingkungan yang bersifat dinamis dan stokastik. Dengan mengumpulkan umpan balik evaluatif dari lingkungan, Reinforcement Learning dapat mengembangkan kebijakan kontrol yang optimal secara bertahap (Karimah Tauhid, Volume 2 Nomor 1 (2023), e-ISSN 2963-590X, 2023). penggunaan algoritma deep reinforcement learning untuk membangun model yang dapat

memaksimalkan profit sekaligus meminimalkan risiko. Dalam hal ini, kami menerapkan Deep Q-Network (DQN) Learning guna mengidentifikasi pola yang menguntungkan dalam lingkungan perdagangan mata uang yang kompleks dan dinamis, serta mengeksplorasi pengaturan yang lebih optimal untuk mencapai akumulasi keuntungan jangka panjang. Algoritma DQN terdiri dari beberapa komponen utama, yaitu: (1) pemodelan fungsi nilai Q untuk setiap kombinasi keadaan dan tindakan, (2) peningkatan stabilitas keseluruhan kerangka kerja selama proses pelatihan, serta (3) pengalaman pengulangan yang bertujuan menghilangkan korelasi antar sampel dan meningkatkan efisiensi pemanfaatannya (**Baradja & Tjendrowasono, 2024**).

4. Analisis dan Diskusi:

- Analisis

CartPole dan LunarLander adalah dua environment yang sering digunakan dalam penelitian Reinforcement Learning (RL), namun memiliki tingkat kompleksitas yang berbeda. CartPole merupakan permasalahan klasik dalam kontrol keseimbangan, di mana sebuah tiang harus dijaga tetap tegak di atas sebuah gerobak dengan hanya dua aksi, yaitu mendorong ke kiri atau ke kanan. Dengan state space yang kecil (hanya empat variabel), algoritma seperti Deep Q-Network (DQN) sudah cukup efektif untuk menyelesaikan masalah ini. Tantangan utamanya adalah bagaimana agent bisa bereaksi dengan cepat untuk menjaga keseimbangan sebelum sistem menjadi tidak stabil. Karena reward diberikan secara sederhana +1 untuk setiap langkah selama tiang tidak jatuh maka agent cenderung berfokus pada eksploitasi secepat mungkin.

Sebaliknya, LunarLander jauh lebih kompleks karena melibatkan dinamika fisika yang lebih rumit. Agent harus mendaratkan wahana dengan aman di permukaan bulan menggunakan empat aksi berbeda: dorongan utama ke atas, dorongan ke kiri, dorongan ke kanan, atau tidak ada dorongan sama sekali. Dengan state space yang lebih besar (delapan variabel, termasuk posisi, kecepatan, sudut rotasi, dan status kaki pendaratan), metode berbasis policy gradient seperti Proximal Policy Optimization (PPO) atau Advantage Actor-Critic (A2C) lebih cocok dibandingkan dengan DQN. Tantangan utama dalam LunarLander bukan hanya mencapai titik pendaratan, tetapi juga mengoptimalkan penggunaan bahan bakar agar tetap efisien. Reward yang diberikan juga lebih

kompleks, di mana agent bisa mendapatkan skor tinggi jika mendarat dengan stabil di zona yang tepat, tetapi bisa dikenai penalti jika terlalu boros dalam penggunaan bahan bakar atau jatuh dengan kecepatan tinggi.

- Diskusi

Jika dibandingkan, CartPole lebih sederhana dan cocok untuk pemula yang ingin memahami dasar-dasar RL dengan cepat, sementara LunarLander lebih realistis karena melibatkan kontrol multi-dimensi dan memerlukan perencanaan strategi yang lebih matang. Pada CartPole, eksplorasi bisa dilakukan secara lebih terbatas karena aksi yang mungkin diambil hanya dua, sedangkan pada LunarLander, eksplorasi menjadi sangat penting karena banyak kemungkinan skenario yang bisa terjadi selama proses pendaratan. Oleh karena itu, meskipun CartPole adalah latihan awal yang baik untuk memahami RL, LunarLander memberikan tantangan lebih nyata yang lebih mendekati aplikasi di dunia nyata, seperti pengendalian drone atau sistem navigasi pesawat luar angkasa.

5. *Assignment:*

Pada praktikum minggu keempat ini, telah dilakukan implementasi dan perbandingan performa agen *Deep Q-Network* (DQN) pada dua lingkungan berbeda, yaitu **CartPole-v1** dan **LunarLander-v2** menggunakan pustaka **OpenAI Gym** dan **TensorFlow**. Agen DQN yang digunakan memiliki dua *neural network* utama, yaitu **Q-Network** untuk menentukan aksi optimal berdasarkan kondisi lingkungan dan **Target Network** yang diperbarui secara berkala untuk stabilisasi pelatihan. Selain itu, agen juga menerapkan **Experience Replay** menggunakan *buffer* untuk menyimpan pengalaman sebelumnya dan meningkatkan efisiensi pembelajaran.

Pada eksperimen pertama dengan **CartPole-v1**, agen bertugas menjaga keseimbangan tiang di atas gerobak/kotak selama mungkin. Agen mendapatkan *reward* +1 setiap langkah selama tiang tetap seimbang, sehingga umpan balik yang sering memungkinkan pembelajaran lebih cepat. Parameter seperti *epsilon decay* (0.995), *replay buffer* (2000), dan *batch size* (32) telah disesuaikan agar eksplorasi berkurang lebih cepat dan agen dapat fokus mengeksploitasi kebijakan yang sudah dipelajari. Hasil pelatihan menunjukkan



bahwa agen dapat meningkatkan skornya secara bertahap dan belajar menjaga keseimbangan tiang lebih lama seiring berjalannya waktu.

Sedangkan, Eksperimen kedua dilakukan pada ***LunarLander-v2***, yang memiliki luar angkasa dengan mengatur dorongan mesin agar dapat mendarat dengan aman di zona yang ditentukan. Tidak seperti *CartPole*, di mana reward diberikan secara lebih sering, dalam ***LunarLander-v2***, agen menerima reward berdasarkan seberapa baik ia mengontrol pendaratan, dengan penalti jika terjadi tabrakan atau pendaratan di luar zona yang ditentukan. Tantangan ini membuat strategi eksplorasi menjadi lebih kompleks.

Untuk meningkatkan performa agen, beberapa parameter diubah, seperti *epsilon decay* yang lebih lambat (0.999) agar agen dapat mengeksplorasi lebih lama sebelum beralih ke eksploitasi, *replay buffer* yang lebih besar (5000) untuk menyimpan lebih banyak pengalaman, serta tambahan reward +100 jika berhasil mendarat dengan stabil. Perubahan ini bertujuan untuk memberi agen lebih banyak kesempatan dalam menemukan strategi optimal sebelum masuk ke tahap eksploitasi penuh.

Secara keseluruhan, eksperimen ini menunjukkan bahwa pemilihan parameter dalam *reinforcement learning* sangat bergantung pada karakteristik lingkungan. Lingkungan dengan reward yang lebih sering, seperti *CartPole*, memungkinkan agen belajar lebih cepat dengan *epsilon decay* yang lebih cepat dan *replay buffer* yang lebih kecil. Sebaliknya, lingkungan yang memberikan reward secara lebih sporadis, seperti *LunarLander-v2*, membutuhkan eksplorasi lebih lama dan *replay buffer* yang lebih besar agar agen dapat mengumpulkan pengalaman yang cukup untuk menemukan strategi pendaratan yang optimal

6. Data dan Output Hasil Pengamatan:

No.	Variabel	Hasil Pengamatan	
		CartPole-v1	LunarLander-v2
1.	Waktu Pelatihan	CartPole lebih cepat mencapai performa optimal dalam waktu yang relatife singkat	LunarLander membutuhkan waktu yang lebih banyak
2.	Jumlah Episode Maksimum	CartPole dilatih hingga 1000 episode sudah cukup untuk mecapai skor maksimal	LunarLander dilatih 5000-10.000 episode agar agent dapat belajar mendarat dengan baik
3.	Skor Maksimum	Skor bervariasi tergantung seberapa lama tiang tetap seimbang dan maksimal skor 500	Agar mendarat dengan presisi membutuhkan skor 300+
4.	Kinerja Agen	Kinerja yang lebih stabil jika skor lebih tinggi	Masih mendarat dengan adanya kecelakaan dan tidak presisi
5.	Kondisi Berhasil	Episode berakhir jika tiang jatuh atau mencapai skor 500	Episode berakhir jika mampu mendarat dengan presisi
6.	Hasil Test Episode serta score dan Visualisai (100 episode dan range 5)	 <pre> Test Episode: 1, Score: 8 Test Episode: 2, Score: 7 Test Episode: 3, Score: 8 Test Episode: 4, Score: 8 Test Episode: 5, Score: 8 </pre>	 <pre> Test Episode: 1, Score: 83 Test Episode: 2, Score: 57 Test Episode: 3, Score: 78 Test Episode: 4, Score: 49 Test Episode: 5, Score: 57 </pre>

7. Kesimpulan:

Berdasarkan praktikum dan analisis yang telah dilakukan, maka dapat diambil kesimpulan yaitu:

- CartPole-v1 lebih cepat dipelajari karena memberikan *reward* di setiap langkah, sehingga agen dapat dengan cepat memahami strategi optimal.
- LunarLander-v2 membutuhkan eksplorasi lebih lama dan *replay buffer* yang lebih besar agar agen dapat mengumpulkan pengalaman yang cukup untuk menemukan strategi pendaratan yang optimal.
- Penggunaan *target network* membantu stabilitas pembelajaran, menghindari perubahan nilai Q yang terlalu drastis.
- *Experience Replay* meningkatkan efisiensi pembelajaran, tetapi ukuran buffer harus disesuaikan dengan kompleksitas lingkungan agar tetap efektif.
- Dikarenakan pada percobaan kali ini menggunakan 100 episode saja setiap environment baik CartPole maupun LunarLander maka hasil visualisasi yang dihasilkan tidak maksimal.

8. Saran:

Untuk meningkatkan performa agen DQN pada lingkungan yang lebih kompleks, disarankan untuk menyesuaikan parameter lebih lanjut melalui eksperimen, seperti menggunakan *dueling DQN*, *prioritized experience replay*, atau peningkatan arsitektur jaringan dengan lebih banyak neuron atau lapisan. Selain itu, untuk kasus seperti MountainCar, pendekatan lain seperti *actor-critic methods* atau *policy-based reinforcement learning* dapat dicoba untuk meningkatkan efisiensi pembelajaran. Lebih jauh, penggunaan *hardware* yang lebih kuat seperti GPU dapat mempercepat proses pelatihan, terutama pada lingkungan dengan kompleksitas tinggi.

9. Daftar Pustaka:

Andreanus, J., & Kurniawan, A. (2018). Sejarah, Teori Dasar dan Penerapan

Reinforcement Learning: Sebuah Tinjauan Pustaka. *Jurnal Telematika*,

12(2), 113–118. <https://doi.org/10.61769/telematika.v12i2.193>

Baradja, A., & Tjendrowasono, T. I. (2024). Pengaplikasian Deep Reinforcement Q-Learning Untuk Prediksi Perdagangan Valas Otomatis. *Jurnal Rekayasa Sistem Informasi dan Teknologi*, 1(3), 190–198.

<https://doi.org/10.59407/jrsit.v1i3.519>

Karimah Tauhid, Volume 2 Nomor 1 (2023), e-ISSN 2963-590X. (2023). 2.